

# Implementasi *Computer Vision* untuk Deteksi Alergen pada Citra Makanan

Ikhlastyar Kalman Achmad<sup>1</sup>, Muhammad Rafli Azrarsyah<sup>2</sup>, Muhammad Faisa Ardha R<sup>3</sup>

<sup>1</sup>Universitas Gadjah Mada, Yogyakarta, email: ikhlastyarkalmanachmad@ugm.ac.id

<sup>2</sup>Universitas Gadjah Mada, Yogyakarta, email: muhammadrafliazrarsyah@ugm.ac.id

<sup>3</sup>Universitas Gadjah Mada, Yogyakarta, email: muhammadfaisaardrar@ugm.ac.id

Corresponding Author: Ikhlastyar Kalman Achmad

**ABSTRAK** — Penelitian ini mengembangkan sistem klasifikasi citra makanan Indonesia untuk mendukung digitalisasi UMKM kuliner dan meningkatkan transparansi informasi alergen. Data kompetisi berisi gambar tanpa label dimanfaatkan melalui *pseudo-labeling* bertahap dengan ambang keyakinan tinggi dan kurasi manual singkat untuk menghasilkan dataset latih yang bersih pada 15 kelas. Tiga *backbone* modern berbobot pralatih dievaluasi, yaitu EfficientNet-V2S, ConvNeXt-Tiny, dan DenseNet-169, menggunakan skema pelatihan dua tahap yang dimulai dari pembekuan *backbone* lalu *fine-tuning* dengan penjadwalan laju belajar. Evaluasi berfokus pada akurasi serta didukung analisis *confusion matrix* untuk memetakan kelas yang kerap tertukar. Untuk meningkatkan stabilitas, prediksi akhir diperoleh dengan *ensemble soft voting* antarmodel. Hasilnya menunjukkan kurva pelatihan yang stabil dan peningkatan akurasi validasi setelah *fine-tuning*, sehingga model layak dioperasionalkan. Kontribusi praktisnya berupa penandaan otomatis yang konsisten lintas kanal dan pelabelan alergen berbasis aturan sederhana agar konsumen memperoleh informasi awal tanpa membebani pelaku usaha. Keterbatasan utama mencakup ketergantungan pada mutu *pseudo-label*, validasi berbasis satu pembagian berstrata, serta sifat penandaan alergen yang indikatif sehingga tetap memerlukan klarifikasi penjual. Temuan ini memperlihatkan bahwa *transfer learning*, *pseudo-labeling*, dan *ensemble* dapat dikombinasikan secara efektif untuk mengubah citra makanan menjadi data terstruktur yang langsung berguna bagi pencarian produk dan informasi alergen.

**KATA KUNCI** — Data mining, Deep learning, Computer vision, Transfer learning, Kuliner, Alergen

## I. PENDAHULUAN

UMKM kuliner memegang peran strategis dalam perekonomian Indonesia, namun banyak pelaku usaha masih terkendala pada tahap digitalisasi dasar, seperti penyusunan katalog menu, konsistensi penamaan produk, dan penyediaan informasi yang relevan bagi konsumen. Di sisi lain, kanal penjualan dan promosi mereka sangat bergantung pada konten visual. Ketimpangan ini, yakni banyaknya foto tanpa metadata terstruktur, membuat produk sulit ditemukan mesin pencari maupun fitur rekomendasi platform. Klasifikasi citra makanan menawarkan jalan keluar dengan mengubah foto menjadi data yang dapat ditindaklanjuti untuk memperbaiki temu balik informasi dan pengalaman belanja.

Topik ini penting karena tanpa pengelolaan data visual yang baik, pelaku UMKM sulit mendapatkan visibilitas, sementara konsumen kesulitan menemukan produk yang sesuai dan informasi dasar seperti bahan yang bisa memicu alergi. Proses memberi label secara manual pada ribuan foto tidak realistik bagi usaha kecil, sehingga otomatisasi dengan teknologi *computer vision* menjadi kebutuhan mendesak, bukan sekadar tambahan. Penelitian yang berfokus pada makanan Indonesia juga memiliki nilai ilmiah yang tinggi, karena makanan lokal memiliki bentuk dan tampilan yang khas serta seringkali mirip antarjenis. Hal ini menuntut pengembangan model yang kuat dan mampu beradaptasi terhadap perbedaan cara penyajian, pencahayaan, serta jenis kamera yang digunakan.

Penelitian ini bertujuan mengembangkan dan mengevaluasi model klasifikasi citra untuk 15 jenis makanan Indonesia serta merancang alur pemaknaan hasil model

menjadi dua fitur inti yang langsung berguna: penandaan atau *tagging* otomatis yang terhubung ke fungsi pencarian, dan pelabelan alergen sederhana berbasis aturan yang diturunkan dari kategori makanan. Secara teknis, penelitian menilai akurasi klasifikasi dan konsistensi tag, serta secara kegunaan menilai seberapa jauh dua fitur tersebut mempercepat pembuatan katalog dan mempermudah penelusuran produk oleh pengguna.

Manfaat penelitian hadir pada dua ranah. Secara teoretis, penelitian berkontribusi pada kajian *transfer learning* untuk domain kuliner Indonesia yang menantang secara visual, serta menawarkan kerangka yang memulai dari citra yang diklasifikasikan menjadi label, kemudian dipetakan menjadi tag, dan pada akhirnya diterjemahkan menjadi aturan operasional yang dapat ditiru pada konteks UMKM lain. Secara praktis bagi UMKM, hasilnya mewujud dalam dua kegunaan utama: pertama, pencarian makanan berbasis *tagging* sehingga produk lebih mudah ditemukan pada etalase digital. kedua, pelabelan alergen sederhana yang meningkatkan transparansi informasi bagi konsumen tanpa membebani pelaku usaha dengan proses anotasi manual yang kompleks.

Batasan dan ruang lingkup penelitian ditetapkan agar fokus analisis terjaga. Kategori dibatasi pada 15 makanan yang didefinisikan sejak awal. Data yang digunakan berupa citra produk, tanpa analisis resep rinci, komposisi nutrisi, atau harga. Pelabelan alergen bersifat indikatif dan berbasis aturan umum, bukan verifikasi komposisi aktual maupun rujukan medis, sehingga tetap memerlukan klarifikasi dari penjual pada tahap transaksi. Cakupan fungsional diarahkan pada dua keluaran

utama, yaitu tagging untuk pencarian dan pelabelan alergen sederhana, dan tidak mencakup peramalan penjualan, rekomendasi harga, atau evaluasi dampak bisnis jangka panjang. Dengan batasan ini, penelitian difokuskan untuk membuktikan bahwa klasifikasi citra dapat segera dioperasionalkan menjadi nilai nyata bagi digitalisasi UMKM kuliner.

## II. STUDI LITERATUR

### A. PENGERTIAN DATA MINING

Data mining merupakan proses ekstraksi pola atau pengetahuan yang bermakna dari kumpulan data berukuran besar dengan memanfaatkan teknik statistik, pembelajaran mesin (*machine learning*), dan pengenalan pola (*pattern recognition*) [1]. Tujuan utama dari data mining adalah menemukan keteraturan, korelasi, atau hubungan tersembunyi yang tidak tampak secara langsung dari data mentah [2]. Dalam konteks yang lebih luas, data mining merupakan bagian dari tahapan *Knowledge Discovery in Databases* (KDD), yang meliputi proses seleksi data, prapengolahan, transformasi, penambangan, dan interpretasi hasil [3].

Pendekatan data mining dapat diterapkan pada berbagai jenis data, termasuk data teks, numerik, dan citra digital. Untuk penelitian ini, proses data mining dilakukan terhadap data citra makanan, dengan tujuan mengklasifikasikan jenis makanan berdasarkan fitur visualnya menggunakan metode pembelajaran mesin tingkat lanjut. Dengan demikian, penelitian ini termasuk ke dalam bidang image classification dalam ranah computer vision, yang merupakan salah satu cabang penting dari data mining berbasis visual [4].

### B. PEMBELAJARAN MESIN DAN DEEP LEARNING

Pembelajaran mesin (*machine learning*) merupakan cabang dari kecerdasan buatan yang memungkinkan sistem komputer belajar dari data tanpa diprogram secara eksplisit [5]. Salah satu paradigma utama dalam pembelajaran mesin modern adalah *deep learning*, yaitu pendekatan berbasis jaringan saraf tiruan berlapis banyak (*deep neural networks*) yang mampu mengekstraksi representasi fitur secara hierarkis [6].

Dalam klasifikasi citra, *Convolutional Neural Network* (CNN) menjadi arsitektur dominan karena kemampuannya mengenali pola spasial melalui operasi konvolusi [7]. CNN secara otomatis mengekstraksi fitur-fitur penting dari gambar tanpa memerlukan rekayasa fitur manual. Arsitektur CNN modern seperti DenseNet, EfficientNet, dan ConvNeXt menunjukkan peningkatan signifikan dalam akurasi dan efisiensi dengan memanfaatkan teknik seperti *residual learning*, *compound scaling*, dan desain blok konvolusi yang dioptimalkan [8], [9].

### C. TRANSFER LEARNING

*Transfer learning* adalah teknik yang memungkinkan peneliti memanfaatkan model yang telah dilatih pada dataset besar, seperti ImageNet, kemudian menyesuaikannya (*fine-tuning*) untuk tugas baru dengan dataset yang lebih kecil

atau berbeda [10]. Pendekatan ini sangat efektif ketika ketersediaan data berlabel terbatas, karena model *pretrained* telah mempelajari representasi umum dari berbagai pola visual [11].

Dalam penelitian ini, empat arsitektur *pretrained* digunakan, yaitu EfficientNet-V2S, ConvNeXt-Tiny, dan DenseNet-169.

- EfficientNet-V2S memperkenalkan Fused-MBConv untuk mempercepat proses pelatihan serta strategi *progressive learning* agar konvergensi lebih stabil pada resolusi tinggi [13].
- ConvNeXt-Tiny mengadaptasi prinsip arsitektur Vision Transformer (ViT) ke dalam CNN konvensional dengan mengoptimalkan kernel besar dan normalisasi layer [14].
- DenseNet-169, melalui konektivitas dense yang menghubungkan setiap layer ke seluruh layer sebelumnya dalam satu *dense block*, meningkatkan aliran informasi dan gradien sehingga efisien dalam memitigasi masalah *vanishing gradient* sekaligus menghasilkan representasi fitur yang lebih kaya dengan jumlah parameter yang lebih hemat dibanding arsitektur konvolusional tradisional. [15].

*Transfer learning* dipilih karena mampu menghemat sumber daya komputasi dan waktu pelatihan, sekaligus menghasilkan performa tinggi meski dengan jumlah data berlabel yang terbatas.

### D. PSEUDO-LABELING DAN SEMI-SUPERVISED LEARNING

*Semi-supervised learning* merupakan pendekatan pembelajaran yang memanfaatkan sejumlah kecil data berlabel bersama sejumlah besar data tak berlabel untuk meningkatkan performa model [16]. Salah satu metode populer dalam kategori ini adalah *pseudo-labeling*, yaitu proses pemberian label buatan terhadap data tak berlabel berdasarkan prediksi model yang dilatih pada subset data berlabel [17].

Prinsip kerjanya adalah sebagai berikut: model awal dilatih menggunakan data berlabel, kemudian digunakan untuk memprediksi label pada data tak berlabel. Prediksi dengan tingkat kepercayaan (*confidence score*) tinggi diterima sebagai *pseudo-label* dan ditambahkan ke kumpulan data pelatihan. Proses ini diulang secara iteratif, sehingga model secara bertahap belajar dari lebih banyak data berlabel semu [18].

Meskipun berisiko menimbulkan label noise jika threshold keyakinan terlalu rendah, *pseudo-labeling* tetap menjadi strategi efektif ketika labeling manual tidak memungkinkan. Dalam penelitian ini, *pseudo-labeling* dilakukan dengan penurunan ambang keyakinan bertahap (mulai dari 0.985) dan disertai inspeksi manual untuk menjaga kualitas label. Pendekatan ini memastikan dataset hasil akhir memiliki distribusi kelas yang konsisten dan akurat.

#### E. ENSEMBLE LEARNING DAN META-LEARNING

Ensemble learning merupakan strategi yang menggabungkan beberapa model pembelajaran dasar (base learners) untuk meningkatkan stabilitas dan akurasi prediksi [19]. Prinsip utamanya adalah bahwa kombinasi beberapa model dengan kelemahan yang berbeda dapat saling menutupi kesalahan masing-masing. Pendekatan umum dalam ensemble meliputi bagging, boosting, dan voting.

Dalam penelitian ini, digunakan metode *soft voting*, yaitu pendekatan di mana setiap model dasar menghasilkan probabilitas prediksi untuk setiap kelas, dan hasil akhir diperoleh dengan menghitung rata-rata tertimbang dari probabilitas tersebut [20]. Teknik ini memungkinkan setiap model berkontribusi secara proporsional terhadap keyakinannya pada suatu kelas, bukan hanya pada keputusan kelas akhir. Dengan demikian, model dengan performa yang lebih baik dapat memiliki pengaruh lebih besar terhadap hasil akhir.

Kelebihan utama *soft voting* dibanding rata-rata keras (*hard voting*) atau agregasi sederhana terletak pada kemampuannya mempertimbangkan tingkat keyakinan antarmodel secara lebih halus. Pendekatan ini menghasilkan prediksi yang lebih stabil dan akurat, terutama ketika model dasar memiliki performa yang relatif seimbang dan beragam [21].

#### F. RINGKASAN STUDI LITERATUR

Berdasarkan uraian teori di atas, penelitian ini mengintegrasikan beberapa pendekatan modern dalam pembelajaran mesin citra yang saling melengkapi. Prosesnya dimulai dengan penerapan *pseudo-labeling* berbasis semi-supervised learning untuk menghasilkan label dari dataset yang semula tidak memiliki anotasi. Tahap ini memungkinkan model memperoleh dasar pengetahuan awal tanpa bergantung sepenuhnya pada data berlabel. Selanjutnya, teknik transfer learning dari model yang telah dilatih sebelumnya digunakan untuk meningkatkan efisiensi dan stabilitas proses pelatihan, sekaligus memanfaatkan representasi fitur yang telah terbentuk pada dataset besar seperti ImageNet. Terakhir, pendekatan meta-learning ensemble diterapkan untuk menggabungkan kekuatan dari berbagai arsitektur CNN sehingga menghasilkan sistem klasifikasi makanan yang lebih robust, efisien, dan memiliki kemampuan generalisasi yang tinggi terhadap data uji yang belum pernah dilihat sebelumnya.

### III. SOLUSI DAN USULAN

Solusi berfokus pada alur yang menjadikan citra sebagai data terstruktur yang konsisten lintas kanal. Model klasifikasi 15 kelas berbasis transfer learning pada EfficientNetV2 dengan kepala GAP menghasilkan label untuk setiap foto, lalu label tersebut dipetakan menjadi tag yang mengikuti taksonomi pada POS, QR menu, dan marketplace. Penegakan mutu dilakukan dengan mekanisme *human in the loop* agar prediksi yang sangat yakin langsung diterapkan, prediksi yang meragukan dikonfirmasi singkat, dan prediksi yang lemah diperbaiki lebih

dahulu. Untuk memastikan keterbacaan dan interoperabilitas, disertakan Lampiran A yang memuat pemetaan label ke tag per kanal sebagai acuan tunggal yang dapat diperbarui versinya dan dilacak perubahannya.

Aspek keamanan informasi bagi konsumen dihadirkan melalui pelabelan alergen sederhana yang bersifat indikatif dan dapat diaudit. Setiap label makanan dihubungkan dengan indikator alergen umum sehingga pemilik gerai dapat memberi informasi dasar tanpa beban anotasi manual yang kompleks. Aturan disusun dalam Lampiran B yang memuat pemetaan label ke indikator potensi alergen. Pada kartu menu, penanda alergen ditampilkan bersama catatan bahwa aturan yang diberikan masih umum, klarifikasi penjual tetap diperlukan saat transaksi menyesuaikan resep yang digunakan. Keandalan dipantau melalui pemeriksaan sampel rutin dan pencatatan perubahan, sedangkan keberhasilan dievaluasi melalui kurangnya waktu input per item, turunnya salah kategori lintas kanal, meningkatnya rasio klik pada hasil pencarian, meningkatnya rasio tambah ke keranjang, serta bertambahnya cakupan label alergen.

Agar dampak solusi berkelanjutan, beberapa pengembangan lanjutan disarankan. Pada sisi model, dilakukan penyetelan ulang berkala dengan contoh lokal terbaru, penerapan augmentasi saat pengujian yang ringan, serta ansambel hemat komputasi untuk menjaga kestabilan performa pada variasi pencahayaan dan perangkat. Pada sisi fungsional, taksonomi diperluas hingga tingkat subkelas, pemeriksaan kualitas visual seperti deteksi gambar buram atau gelap ditambahkan, dan informasi judul digabungkan dengan fitur visual melalui pengendali berbasis aturan agar tetap ringan bagi pelaku usaha. Pada sisi operasional dan tata kelola, disiapkan pengelolaan versi untuk taksonomi dan aturan alergen, dasbor pemantauan indikator kinerja bagi pemilik gerai, serta pedoman etika dan mekanisme umpan balik koreksi sehingga katalog semakin rapi, pencarian semakin akurat, dan transparansi informasi semakin kuat tanpa menambah beban kerja.

### IV. METODE PENELITIAN

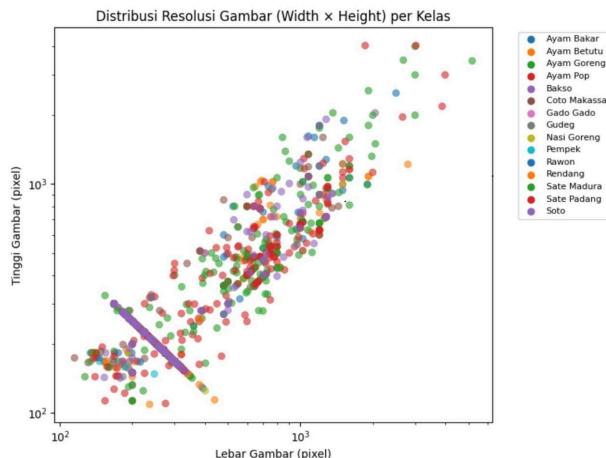
Bab ini menjelaskan langkah-langkah penelitian secara sistematis mulai dari sumber data, karakteristik dataset, alur metodologi, prapengolahan data, *pseudo-labeling semi-supervised*, hingga konstruksi dan pelatihan model utama. Metodologi disusun untuk menangani kondisi dataset yang tidak memiliki label secara langsung, sehingga diperlukan pendekatan bertahap yang menggabungkan inspeksi manual, *pseudo-labeling*, dan *fine-tuning* model *deep learning* berbasis transfer learning. Seluruh proses dirancang untuk menghasilkan model klasifikasi yang *robust* dan dapat melakukan inferensi pada data uji kompetisi.

#### G. SUMBER DAN DESKRIPSI DATASET

Dataset yang digunakan dalam penelitian ini berasal dari kompetisi Data Mining ACTION 2025 yang diselenggarakan melalui platform Kaggle. Kompetisi ini mengangkat tema

klasifikasi citra makanan Indonesia dengan konteks umum pemberdayaan UMKM, sebagaimana dijelaskan pada booklet resmi. Namun, versi dataset yang tersedia di Kaggle tidak menyertakan informasi tambahan selain berkas gambar dan daftar kelas.

Dataset terdiri atas dua bagian utama, yaitu *train* sebanyak 4.287 gambar dan *test* sebanyak 2.057 gambar. Seluruh gambar pada set *train* disediakan tanpa label, sehingga perlu dilakukan proses pelabelan sebelum dapat digunakan untuk membangun model klasifikasi. Sementara itu, set *test* digunakan semata-mata untuk inferensi akhir sesuai format kompetisi.



**Gambar 1.** Distribusi Resolusi Gambar Berdasarkan Kelas Makanan

Secara karakteristik, file gambar memiliki format bervariasi (umumnya .jpg) dengan ukuran yang tidak seragam, mulai dari resolusi rendah seperti 64 piksel hingga resolusi sangat tinggi mencapai  $5.040 \times 4.032$  piksel. Variasi lain yang ditemukan meliputi perbedaan aspek rasio, kualitas pencahayaan, komposisi makanan, dan kondisi pengambilan gambar. Dataset mencakup 15 kelas makanan, yaitu: Ayam Bakar, Ayam Betutu, Ayam Goreng, Ayam Pop, Bakso, Coto Makassar, Gado Gado, Gudeg, Nasi Goreng, Pempek, Rawon, Rendang, Sate Madura, Sate Padang, dan Soto. Distribusi kelas relatif seimbang dengan kisaran sekitar 240–300 gambar per kelas setelah proses *pseudo-labeling* dan pembersihan dilakukan.

Setelah dataset memperoleh *pseudo-label* yang telah diperiksa ulang secara manual, dilakukan pembagian internal dengan skema *stratified split* sebesar 80% untuk pelatihan, 10% untuk validasi, dan 10% untuk pengujian internal. *Split* ini memastikan setiap kelas terdistribusi secara proporsional.

#### H. OVERVIEW ALUR METODOLOGI

Secara umum, metodologi penelitian ini mengikuti alur proses bertahap yang dimulai dari dataset tanpa label hingga menghasilkan model ensemble untuk prediksi akhir. Alur tersebut dapat diringkas sebagai berikut:

1. Pilih 20 sampel representatif per kelas,
2. Latih seed model kecil,
3. Lakukan *pseudo-labeling* iteratif (ambang menurun),
4. Inspeksi manual dan bersihkan label,
5. Prapengolahan dan augmentasi data,
6. Latih 4 model transfer learning,

7. Validasi berstrata dan simpan bobot terbaik,
8. Ansambel keluaran model,
9. Prediksi akhir pada data uji, dan
10. Susun berkas submission.

Proses *pseudo-labeling* yang menjadi inti penelitian dilakukan secara iteratif untuk mengurangi kemungkinan *noise* dalam label, sementara pembangunan model utama memanfaatkan arsitektur *pretrained* berukuran sedang agar seimbang antara kapasitas representasi dan risiko *overfitting*. Tahap akhir melibatkan *ensemble* untuk meningkatkan stabilitas prediksi.

#### I. PRA-PENGOLAHAN DATA



**Gambar 2.** Sampel Dataset Setelah Proses Resize ke Resolusi 384×384

Sebelum data digunakan untuk pelatihan model, dilakukan serangkaian proses prapengolahan. Seluruh gambar di-*resize* menjadi  $320 \times 320$  piksel untuk menyamakan dimensi input antarmodel. Proses pembersihan awal dilakukan untuk memastikan tidak terdapat gambar yang rusak atau tidak dapat dibaca. Selain itu, seluruh gambar dikonversi ke format yang konsisten serta dinormalisasi sesuai kebutuhan *preprocessing model pretrained*, misalnya penskalaan ke rentang [0, 1] atau normalisasi berbasis statistik ImageNet.

Untuk meningkatkan generalisasi model, diterapkan teknik augmentasi data. Augmentasi dasar yang digunakan mencakup *random horizontal flip*, *random rotation*, *random crop/resize*, dan *brightness/contrast jitter*. Pada beberapa model, diterapkan augmentasi tambahan seperti *cutout*, *mixup*, atau *cutmix* untuk menambah keragaman distribusi input. Variasi augmentasi antarmodel dilakukan dengan tujuan memperluas diversifikasi representasi yang nantinya berkontribusi pada kualitas *ensemble*.

Setelah proses *pseudo-labeling* selesai dan label telah dibersihkan secara manual, dataset dibagi menggunakan skema *stratified split* sebesar 80% untuk pelatihan, 10% untuk validasi, dan 10% untuk pengujian internal.

#### J. STRATEGI PSEUDO-LABELING (SEMI-SUPERVISED)

Karena dataset latih tidak menyertakan label, penelitian ini menggunakan pendekatan *pseudo-labeling semi-supervised* untuk menghasilkan label awal sebelum melatih model utama. Tahap pertama dilakukan dengan memilih 20 sampel representatif untuk setiap kelas (total 300 gambar) berdasarkan

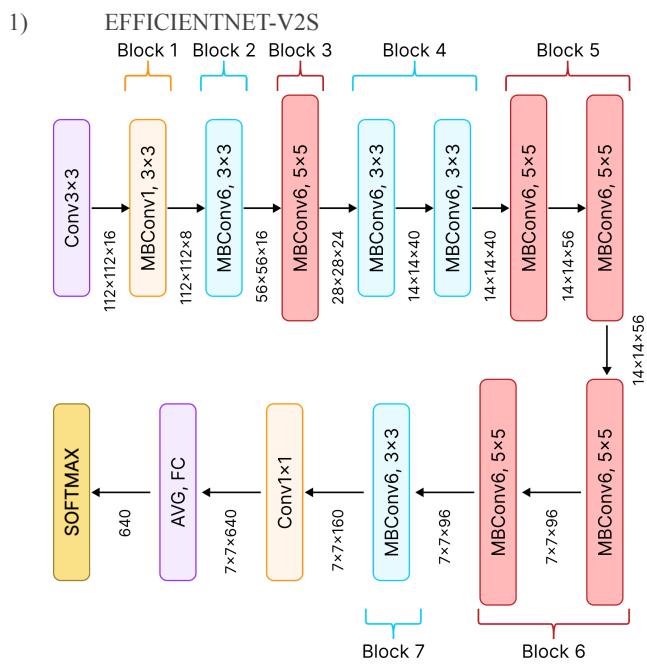
inspeksi manual dan informasi deskriptif kelas yang tersedia. Sampel ini berfungsi sebagai dataset berlabel awal yang digunakan untuk melatih model awal berukuran kecil.

Model awal yang digunakan adalah EfficientNet-B0 *pretrained* ImageNet. Setelah pelatihan awal, model digunakan untuk memprediksi label pada seluruh dataset *train* yang belum berlabel. Hanya prediksi dengan probabilitas di atas ambang tertentu yang diterima sebagai *pseudo-label*. *Threshold* awal ditetapkan pada 0.985 dan secara bertahap diturunkan sebesar 0.007 di setiap iterasi untuk menyeimbangkan jumlah sampel berlabel dan potensi *noise*. Selain itu, pada setiap iterasi hanya 300 prediksi dengan *confidence* tertinggi yang ditambahkan ke kumpulan data berlabel, sehingga proses *labeling* berlangsung hati-hati dan terkontrol.

Proses pelatihan, prediksi, seleksi dijalankan secara berulang hingga seluruh gambar memperoleh *pseudo-label*. Setelah itu dilakukan inspeksi manual per kelas untuk memverifikasi konsistensi label dan memperbaiki kesalahan prediksi yang muncul. Dari proses ini ditemukan sejumlah kesalahan yang kemudian dikoreksi secara manual. Tahap ini menghasilkan dataset latih yang bersih dan terlabel secara konsisten untuk pelatihan model utama.

#### K. ARSITEKTUR DAN STRATEGI PELATIHAN MODEL UTAMA

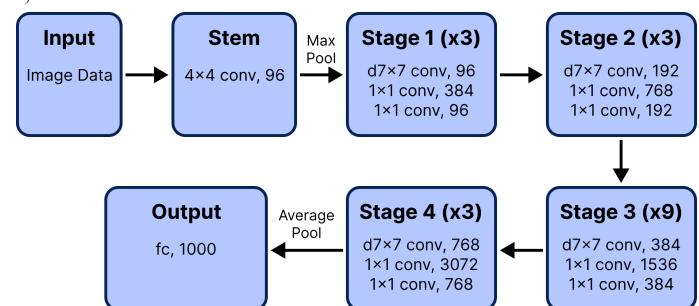
Model utama yang digunakan dalam penelitian ini terdiri atas empat arsitektur *pretrained*, yaitu EfficientNet-V2S, ConvNeXt-Tiny, dan DenseNet-169. Pemilihan arsitektur ini mempertimbangkan keseimbangan antara kapasitas representasi fitur dan risiko overfitting. Model berukuran sedang (sekitar 20–30 juta parameter) dianggap sesuai untuk dataset berukuran menengah dengan variasi visual yang tinggi. Selain itu, penggunaan arsitektur yang berbeda memungkinkan terciptanya variasi representasi yang bermanfaat untuk *ensemble*.



Gambar 3. Skema Arsitektur EfficientNet-V2S dan Desain Blok Utamanya

EfficientNet-V2S adalah versi pengembangan dari EfficientNet generasi pertama, dengan fokus pada *training speed* dan efisiensi saat digunakan pada resolusi lebih tinggi. Model ini menggantikan sebagian MBConv dengan Fused-MBConv, yang menggabungkan operasi ekspansi dan convolution menjadi satu langkah sehingga proses *training* lebih cepat pada GPU modern. Selain itu, EfficientNet-V2 memperkenalkan strategi *progressive learning*, yaitu menaikkan input *resolution* secara bertahap selama latihan untuk mempercepat konvergensi. Versi “S” (*small*) menawarkan keseimbangan antara kecepatan dan akurasi, sehingga ideal sebagai *backbone* untuk tugas klasifikasi multi-kelas dengan jumlah data besar dan variasi visual tinggi. [22].

#### 2) CONVNEXT-TINY

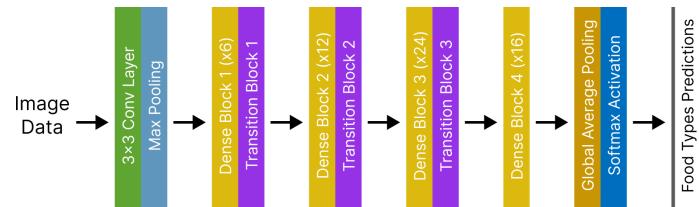


Gambar 4. Arsitektur Model ConvNeXt-Tiny beserta Struktur Internal

#### ConvNeXt Block

ConvNeXt-Tiny adalah arsitektur CNN modern yang terinspirasi oleh desain Vision Transformer (ViT), namun mempertahankan struktur convolutional yang lebih stabil dan efisien. Model ini memodifikasi konvolusi klasik menjadi lebih “*transformer-like*” melalui kernel yang lebih besar, penggunaan *Layer Normalization*, blok sederhana berisi konvolusi *depthwise*, dan penghilangan operasi yang tidak efisien seperti ReLU berlebihan. Hasilnya adalah CNN yang mencapai performa sekelas transformer pada benchmark modern seperti ImageNet, tetapi tetap lebih ringan dan lebih mudah dioptimasi. Versi Tiny adalah konfigurasi paling kecil, menjadikannya cocok untuk eksperimen yang membutuhkan speed, stabilitas *training*, dan generalisasi yang baik. [23].

#### 3) DENSENET-169



Gambar 5. Diagram Arsitektur DenseNet-169 dengan GAP dan Softmax

Gambar tersebut menunjukkan alur pemrosesan sebuah model berbasis arsitektur DenseNet, di mana citra masukan terlebih dahulu melalui lapisan konvolusi awal berukuran 3x3 dan operasi max-pooling sebelum memasuki empat *dense block* berurutan yang masing-masing dihubungkan oleh *transition block* untuk mengontrol ukuran fitur serta menjaga efisiensi komputasi. Setiap *dense block* terdiri dari sejumlah

lapisan yang saling terhubung secara densitas penuh sehingga fitur dari semua lapisan sebelumnya ikut mengalir ke lapisan berikutnya, memperkuat propagasi informasi dan mengurangi risiko hilangnya gradien. Setelah blok terakhir, fitur diringkas melalui *global average pooling* dan diklasifikasikan menggunakan fungsi aktivasi *softmax*, menghasilkan probabilitas kelas akhir. [24].

Pelatihan model dilakukan menggunakan framework TensorFlow dan Keras. Setiap model dilatih dengan strategi *transfer learning* bertahap. Pada tahap pertama, *backbone pretrained* dibekukan (*freeze*), dan hanya lapisan *classifier (head)* yang dilatih menggunakan *optimizer* AdamW dengan *learning rate* 1e-3 selama sekitar 20 epoch. Setelah stabil, proses dilanjutkan ke tahap *fine-tuning*, di mana sebagian atau seluruh *backbone* dibuka kembali dan dilatih dengan *learning rate* lebih rendah (1e-4) selama sekitar 25 epoch.

Untuk menjaga stabilitas pelatihan, digunakan beberapa teknik tambahan seperti *cosine decay* untuk penjadwalan *learning rate*, *Exponential Moving Average* (EMA) pada parameter model, serta *early stopping* berdasarkan performa pada validation set. *Loss function* yang digunakan adalah *categorical crossentropy*, sementara *batch size* diatur sesuai kapasitas GPU. Variasi augmentasi diterapkan secara berbeda antarmodel untuk menambah keberagaman representasi fitur yang akhirnya memperkuat performa *ensemble*.

#### L. VALIDASI, METRIK, DAN EVALUASI

$$\text{accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

Keterangan:

- TP: *True Positive*, jumlah sampel positif yang terkласifikasi benar.
- TN = *True Negative*, jumlah sampel negatif yang terkласifikasi benar.
- FP = *False Positive*, jumlah sampel negatif yang terkласifikasi salah sebagai positif.
- FN = *False Negative*, jumlah sampel positif yang terkласifikasi salah sebagai negatif.

Rumus tersebut menggambarkan perbandingan antara jumlah prediksi benar dengan total keseluruhan sampel yang dievaluasi. Untuk memahami lebih lanjut hubungan antara hasil prediksi dan nilai aktual, digunakan *confusion matrix* sebagai representasi distribusi klasifikasi model. Matriks ini memberikan gambaran menyeluruh mengenai proporsi kesalahan dan ketepatan prediksi pada masing-masing kelas.

Tabel 1. Confusion Matrix

	<i>Predicted Positive</i>	<i>Predicted Negative</i>
<i>Actual Positive</i>	<i>True Positive</i>	<i>False Negative</i>
<i>Actual Negative</i>	<i>False Positive</i>	<i>True Negative</i>

Dengan,

- *True Positive*: Jumlah kasus positif yang diklasifikasikan dengan benar.
- *True Negative*: Jumlah kasus negatif yang diklasifikasikan dengan benar.
- *False Positive*: Jumlah kasus negatif yang salah diklasifikasikan sebagai positif.
- *False Negative*: Jumlah kasus positif yang salah diklasifikasikan sebagai negatif.

Evaluasi kinerja berfokus pada akurasi sesuai ketentuan kompetisi. Perhitungan dilakukan pada data validasi yang diperoleh dari pemisahan berstrata setelah proses *pseudo labeling* dan kurasi. Selain akurasi, penelitian ini memantau precision, recall, dan F1-score per kelas untuk mengidentifikasi kesenjangan kinerja antar kelas. Analisis dilengkapi *confusion matrix* guna memetakan pola salah klasifikasi, misalnya kekeliruan antara Sate Padang dan Sate Madura atau antar menu ayam dengan teknik memasak yang serupa.

Prosedur validasi menggunakan pemisahan berstrata dengan porsi pelatihan 80 persen, validasi 10 persen, dan uji internal 10 persen. Set validasi dipakai untuk memilih model terbaik melalui penyimpanan *checkpoint* berdasarkan akurasi validasi tertinggi. Selama pelatihan, metrik dipantau pada setiap epoch. *Early stopping* diaktifkan ketika metrik validasi tidak membaik dalam sejumlah epoch sesuai nilai *patience*, sehingga membantu mencegah kelebihan pencocokan dan menghemat sumber daya komputasi. Pelaporan metrik memuat ringkasan tingkat makro serta, bila relevan, ringkasan per kelas agar terlihat kelas yang masih lemah.

Untuk analisis kesalahan, beberapa contoh citra yang salah terkласifikasi ditinjau secara kualitatif. Faktor yang diperhatikan mencakup pencahayaan, sudut pengambilan, tata saji, serta kemiripan tekstur atau saus. Hasil peninjauan menjadi masukan untuk penyempurnaan skema augmentasi atau penalaan hiperparameter pada percobaan berikutnya.

#### M. ENSEMBLE DAN PREDIKSI AKHIR

Tahap inferensi menggunakan ensemble dari empat model utama guna meningkatkan ketangguhan prediksi. Metode yang dipakai ialah rata-rata probabilitas atau *soft voting*. Setiap model menghasilkan vektor probabilitas untuk lima belas kelas, kemudian seluruh vektor dirata-ratakan per komponen. Kelas dengan nilai rata-rata tertinggi ditetapkan sebagai prediksi akhir. Pendekatan ini dipilih karena sederhana, stabil, dan efektif mengurangi varians kesalahan antarmodel yang memiliki karakter arsitektur berbeda. Bobot setiap model dapat disetarakan. Jika diperlukan, bobot dapat disesuaikan menurut akurasi validasi masing-masing.

Tidak ada pascapemrosesan khusus selain pemetaan label sesuai daftar kelas kompetisi. Hasil akhir disusun dalam berkas CSV dengan dua kolom, yaitu ID dan label. Kolom ID berisi penanda citra sesuai format panitia, sedangkan kolom label berisi nama kelas yang tepat. Berkas CSV ini menjadi artefak

untuk pengunggahan dan dasar perbandingan kinerja pada papan skor kompetisi.

#### N. REPLIKASI DAN IMPLEMENTASI

Lingkungan eksperimen dijelaskan agar proses dapat diulang oleh peneliti lain. Pelatihan dijalankan pada unit pemroses grafis atau GPU kelas menengah ke atas dengan sistem operasi yang umum digunakan. Kerangka kerja yang digunakan ialah *TensorFlow* dan *Keras*. Versi perangkat lunak serta pustaka utama dicantumkan dalam berkas kebutuhan agar pemasangan berlangsung konsisten. Struktur folder untuk data, model, dan keluaran diatur jelas sehingga alur kerja mudah diikuti.

Upaya keterulangan diwujudkan melalui penetapan nilai benih acak pada seluruh komponen yang relevan, seperti pengacak pada *NumPy*, *TensorFlow*, dan pembangkit augmentasi. Skrip pelatihan menyediakan argumen untuk memanggil konfigurasi yang sama, antara lain ukuran berkas pelatihan, laju belajar, jumlah epoch, dan kebijakan henti dini. Model dan bobot terbaik berdasarkan akurasi validasi disimpan sebagai berkas terpisah. Disediakan pula panduan singkat untuk menjalankan pelatihan, melakukan inferensi, dan menghasilkan berkas CSV akhir.

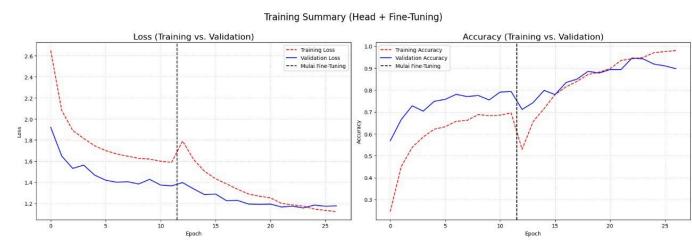
Aspek etika dan pemanfaatan data diperhatikan. Seluruh citra digunakan sesuai ketentuan kompetisi dan hanya untuk tujuan penelitian. Setiap identitas yang mungkin muncul pada citra tidak digunakan untuk tujuan diluar klasifikasi menu. Sumber data dirujuk dengan jelas pada bagian data dan lampiran.

#### O. KETERBATASAN METODE

Metode yang digunakan memiliki beberapa keterbatasan. Validasi dilakukan dengan pembagian berstrata satu kali. Pendekatan ini sederhana, tetapi dapat menimbulkan varians hasil yang lebih tinggi dibandingkan validasi lipat silang. Mutu label sangat bergantung pada proses pseudo labeling. Meskipun ambang keyakinan tinggi dan kurasi manual telah diterapkan, sebagian kesalahan pelabelan masih mungkin terjadi. Jumlah koreksi manual yang besar juga memerlukan waktu serta ketelitian, dan apabila kurasi tidak merata antarkelas, risiko bias dapat meningkat. Strategi pelatihan serta pemilihan arsitektur difokuskan pada model berukuran menengah untuk menyeimbangkan sumber daya dengan kinerja, namun pendekatan ini belum tentu optimal bagi kebutuhan kapasitas yang lebih besar atau penalaan hiperparameter yang lebih agresif. Selain itu, data validasi internal mungkin belum sepenuhnya mewakili data uji kompetisi, sehingga kinerja pada papan skor dapat berbeda dari hasil pengujian internal.

#### V. HASIL DAN ANALISIS PENGUJIAN

Ketiga model EfficientNet-V2S, ConvNeXt-Tiny, dan DenseNet-169 dilatih dengan menggunakan data train yang dibagi menjadi data latih dan validasi dengan rasio 80:20. Setelah dilatih dengan tiga model berbeda, didapat hasil dibawah ini.



Gambar 6. Ringkasan Proses Pelatihan Model (Training Head dan Fine-Tuning)

Grafik ini menampilkan ringkasan proses pelatihan model yang dibagi menjadi dua tahap, yaitu *training head* lalu *fine tuning*. Pada panel kiri terlihat kurva loss untuk *data training* dan *validation* yang sama-sama menurun seiring bertambahnya epoch. Titik garis vertikal menandai dimulainya *fine tuning*, di mana loss turun lebih cepat dan stabil. Pola penurunan ini menunjukkan bahwa model mampu beradaptasi dengan baik setelah seluruh layer dibuka, dan *overfitting* tampak minimal karena jarak antara *training loss* dan *validation loss* tetap terkontrol.

Pada panel kanan ditampilkan kurva akurasi untuk *training* dan *validation*. Keduanya meningkat secara konsisten, dengan kenaikan lebih signifikan setelah proses *fine tuning* dimulai. Akurasi *validation* mendekati akurasi *training*, yang menandakan generalisasi model berada pada tingkat yang baik. Secara keseluruhan kedua grafik ini memberikan gambaran yang jelas bahwa pendekatan dua tahap berhasil meningkatkan performa model secara stabil dan terukur.

Tabel 2. Perbandingan Nilai Akurasi Data Latih dengan Data Validasi

Model	Data Latih	Data Validasi
ConvNeXtTiny	98.9%	94.0%
EfficientNetV2S	96.7%	93.6%
DenseNet169	95.1%	93.0%

Nilai akurasi pada data latih menunjukkan bahwa ketiga model mampu mempelajari pola visual dengan sangat baik, tetapi perbedaan yang muncul antara akurasi latih dan validasi perlu dibaca secara kritis. ConvNeXt-Tiny memiliki akurasi latih tertinggi, yaitu 98.9 persen, namun selisihnya dengan akurasi validasi cukup besar. Hal ini mengisyaratkan bahwa model menangkap pola secara kuat pada data latih, tetapi sebagian kemampuan tersebut tidak sepenuhnya terbawa ke data validasi. Seorang skeptis akan mempertanyakan apakah model ini mulai belajar detail spesifik yang tidak muncul di data validasi atau apakah augmentasi kurang mengimbangi variasi visual. EfficientNetV2S dan DenseNet169 memiliki akurasi latih lebih rendah, tetapi selisih latih validasi yang sedikit lebih rapat dapat mencerminkan pembelajaran yang lebih stabil, meskipun tetap ada ruang untuk menguji kembali apakah regularisasi sudah optimal.

Akurasi validasi ketiga model berada pada kisaran 93 persen, yang berarti performanya relatif konsisten. Namun, keseragaman angka ini tidak otomatis membuktikan bahwa semua model memiliki generalisasi yang sama dalam konteks data yang lebih sulit. Perlu ditelaah apakah kesalahan yang muncul pada validasi berasal dari kelas yang sama atau karakter visual tertentu. Jika pola kesalahan tumpang tindih, kemungkinan ada batasan yang berasal dari dataset, bukan semata arsitektur. Selain itu, selisih performa yang kecil antarmodel mengajak kita mempertanyakan apakah ensemble betul betul menghasilkan kontribusi signifikan atau hanya menggabungkan model dengan bias kesalahan yang serupa. Dengan menguji ulang distribusi prediksi dan tingkat ketidakpastiannya, kita dapat menilai apakah generalisasi sudah cukup kuat atau masih ada indikasi *overfitting* halus yang tidak terlihat hanya dari angka akurasi.

Dari ketiga model tersebut, dibangun meta model berupa regresi linear yang akan mencari hubungan antara bagaimana ketiga model tersebut memprediksi data test dengan hasilnya dengan belajar pada data validasi. Setelah itu, meta model akan digunakan untuk memprediksi data test.

## VI. KESIMPULAN

Penelitian ini membuktikan bahwa rangkaian pendekatan yang digunakan mulai dari pseudo labeling, transfer learning, hingga ensemble dapat menghasilkan model klasifikasi citra makanan yang akurat dan stabil. Proses pelabelan awal yang dilakukan secara bertahap mampu mengatasi ketiadaan label pada dataset kompetisi dan menghasilkan data latih yang bersih. Tahap pelatihan dua fase, yaitu training head dan fine tuning, menghasilkan kurva loss dan akurasi yang menunjukkan pola konvergensi yang baik. Hasil validasi yang berada di kisaran 93 persen menegaskan bahwa model mampu mempelajari pola visual secara efektif dan tetap menjaga kemampuan generalisasi pada data yang tidak dilihat selama pelatihan.

Temuan ini tidak hanya memenuhi tujuan utama penelitian, tetapi juga memberikan bukti kuat bahwa solusi yang diusulkan dapat dioperasionalkan dalam konteks nyata. Pemanfaatan hasil klasifikasi untuk sistem tagging lintas kanal dan pelabelan alergen sederhana menunjukkan bahwa model tidak berhenti pada tingkat teknis saja, melainkan diterjemahkan menjadi manfaat langsung bagi UMKM kuliner. Proses tagging otomatis dapat mempercepat pembuatan katalog produk dan meningkatkan ketercapaian pencarian, sementara penandaan alergen membantu meningkatkan transparansi informasi yang secara praktis mendukung pengalaman konsumen. Dengan demikian penelitian ini berhasil menjawab permasalahan inti yang diajukan pada rumusan masalah awal.

Kontribusi utama penelitian dapat dilihat dari integrasi metode modern dalam satu alur data mining yang teruji dan dapat direplikasi. Pendekatan pseudo labeling bertahap membantu meminimalkan noise, penggunaan beberapa arsitektur pretrained meningkatkan stabilitas prediksi, dan ensemble berperan dalam menyempurnakan hasil akhir. Meski

demikian masih terdapat ruang untuk pengembangan seperti validasi lipat silang yang lebih komprehensif, penguatan skema augmentasi, serta eksplorasi multimodal yang menggabungkan teks dan visual. Secara keseluruhan penelitian ini memberi dasar yang solid untuk pengembangan lebih lanjut sekaligus menghadirkan kontribusi praktis dan ilmiah yang relevan bagi ekosistem data mining di bidang kuliner.

**REFERENSI**

- [1] J. Han, M. Kamber, and J. Pei, Data Mining: Concepts and Techniques, 3rd ed. Elsevier, 2012.
- [2] I. H. Witten, E. Frank, and M. A. Hall, Data Mining: Practical Machine Learning Tools and Techniques, 4th ed. Morgan Kaufmann, 2016.
- [3] U. Fayyad, G. Piatetsky-Shapiro, and P. Smyth, "From data mining to knowledge discovery in databases," *AI Magazine*, vol. 17, no. 3, pp. 37–54, 1996.
- [4] R. Szeliski, Computer Vision: Algorithms and Applications, 2nd ed. Springer, 2022.
- [5] T. M. Mitchell, Machine Learning. McGraw-Hill, 1997.
- [6] I. Goodfellow, Y. Bengio, and A. Courville, Deep Learning. MIT Press, 2016.
- [7] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, pp. 436–444, 2015.
- [8] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in Proc. IEEE CVPR, 2016, pp. 770–778.
- [9] A. Howard et al., "Searching for MobileNetV3," in Proc. IEEE ICCV, 2019, pp. 1314–1324.
- [10] S. J. Pan and Q. Yang, "A survey on transfer learning," *IEEE Trans. Knowl. Data Eng.*, vol. 22, no. 10, pp. 1345–1359, 2010.
- [11] M. Tan and Q. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in Proc. ICML, 2019, pp. 6105–6114.
- [12] M. Tan and Q. Le, "EfficientNetV2: Smaller models and faster training," in Proc. ICML, 2021, pp. 10096–10106.
- [13] Z. Liu et al., "A ConvNet for the 2020s," in Proc. IEEE CVPR, 2022, pp. 11976–11986.
- [14] K. He et al., "Identity mappings in deep residual networks," in Proc. ECCV, 2016, pp. 630–645.
- [15] F. Iandola et al., "SqueezeNet: AlexNet-level accuracy with 50x fewer parameters and <0.5MB model size," arXiv:1602.07360, 2016.
- [16] D.-H. Lee, "Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks," in Workshop on Challenges in Representation Learning, ICML, 2013.
- [17] X. Zhu and A. Goldberg, "Introduction to semi-supervised learning," *Synthesis Lectures on Artificial Intelligence and Machine Learning*, vol. 3, no. 1, pp. 1–130, 2009.
- [18] L. Rokach, "Ensemble-based classifiers," *Artificial Intelligence Review*, vol. 33, no. 1, pp. 1–39, 2010.
- [19] D. Wolpert, "Stacked generalization," *Neural Networks*, vol. 5, no. 2, pp. 241–259, 1992.
- [20] A. Géron, Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, 3rd ed. O'Reilly Media, 2023.
- [21] M. Mingxing Tan dan Quoc V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," arXiv preprint arXiv:1905.11946, May 2019.
- [22] M. Mingxing Tan dan Quoc V. Le, "EfficientNetV2: Smaller Models and Faster Training," arXiv preprint arXiv:2104.00298, Apr 2021.
- [23] Zhuang Liu, Hanzi Mao, Chao-Yuan Wu, Christoph Feichtenhofer, Trevor Darrell, dan Saining Xie, "A ConvNet for the 2020s," arXiv preprint arXiv:2201.03545, Jan 2022
- [24] G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger, "Densely Connected Convolutional Networks," in Proc. CVPR, 2017, pp. 4700–4708.
- [25] D. C. Shekhar, A. G. de Silva, dan M. K. Ramesh, "Food Allergens: Classification and Clinical Relevance," *Journal of Food Science and Technology*, vol. 59, no. 3, pp. 812–825, Mar. 2022, doi: 10.1007/s13197-021-05039-z.
- [26] U.S. Food and Drug Administration (FDA), *Food Allergen Labeling and Consumer Protection Act (FALCPA)*, Silver Spring, MD, USA: FDA, 2022. [Online]. Available: <https://www.fda.gov/food/food-allergens>

**LAMPIRAN**

Lampiran A: Pemetaan Label

Makanan	Tag Master (Kategori)	POS	QR Menu	Marketplace
---------	-----------------------	-----	---------	-------------

	Induk)			
Ayam Bakar	Mains › Ayam	Makanan › Ayam	Main Course	Ayam & Olahan
Ayam Betutu	Mains › Ayam	Makanan › Ayam	Main Course	Ayam & Olahan
Ayam Goreng	Mains › Ayam	Makanan › Ayam	Main Course	Ayam & Olahan
Ayam Pop	Mains › Ayam	Makanan › Ayam	Main Course	Ayam & Olahan
Bakso	Mains › Bakso	Makanan › Bakso	Soups	Bakso
Coto Makassar	Mains › Sup/Kuah	Makanan › Sup/Kuah	Soups	Sup & Soto
Gado Gado	Mains › Sayuran/Salad	Makanan › Sayur/Salad	Salads	Sayuran
Gudeg	Mains › Masakan Nusantara	Makanan › Masakan Jawa	Main Course	Masakan Jawa
Nasi Goreng	Mains › Nasi	Makanan › Nasi	Main Course	Nasi Goreng
Pempek	Mains › Olahan Ikan	Makanan › Olahan Ikan	Snacks	Pempek
Rawon	Mains › Daging Sapi/Kuah	Makanan › Daging Sapi	Soups	Masakan Jawa
Rendang	Mains › Daging Sapi	Makanan › Daging Sapi	Main Course	Masakan Padang
Sate Madura	Mains › Sate	Makanan › Sate	Main Course	Sate
Sate Padang	Mains › Sate	Makanan › Sate	Main Course	Sate
Soto	Mains › Sup/Kuah	Makanan › Sup/Kuah	Soups	Sup & Soto

Lampiran B: Potensi Alergen untuk 15 Makanan

Jenis Makanan	Potensi Alergen
Ayam Bakar	Udang/ikan (dari terasi), bawang.
Ayam Betutu	Gluten (tepung terigu), bawang, minyak kacang (jika digunakan).
Ayam Goreng	Santan (intoleransi pada beberapa orang), bawang.
Ayam Pop	Protein sapi, gluten (jika tepung tambahan mengandung gandum), telur, MSG.
Bakso	Kacang tanah, protein sapi, bawang.
Coto Makassar	Kacang tanah, kedelai (tahu, tempe, kecap), telur (jika digunakan).
Gado-Gado	Santan, telur.
Gudeg	Telur, kedelai, gluten, seafood (jika pakai udang), bawang.
Nasi Goreng	Ikan, gluten (jika ada tepung tambahan), bawang putih.

Pempek	Protein sapi, bawang, kemungkinan kacang (jika ada bahan tambahan kacang tanah goreng).
Rawon	Protein sapi, bawang, kemungkinan kacang (jika ada bahan tambahan kacang tanah goreng).
Rendang	Protein sapi, santan, bawang.
Sate Madura	Kacang tanah, kedelai (kecap), bawang, gluten (jika kecap berbasis gandum).
Sate Padang	Protein sapi, bawang, gluten (jika tepung terigu digunakan), MSG.
Soto	Protein ayam/sapi, telur, bawang, gluten (bihun berbasis gandum pada beberapa varian).